

COLÉGIO TÉCNICO DA UNICAMP

Arthur Gama Jorge

Daniel Dorigan de Carvalho Campos

Ion Mateus Nunes Oprea

PREVIDENGUE:

**Plataforma que utiliza Inteligência Artificial para monitorar e prever surtos de dengue,
combinando detecção de focos e previsão epidemiológica**

CAMPINAS/SP
2025

Arthur Gama Jorge

Daniel Dorigan de Carvalho Campos

Ion Mateus Nunes Oprea

PREVIDENGUE:

Plataforma que utiliza Inteligência Artificial para monitorar e prever surtos de dengue, combinando detecção de focos e previsão epidemiológica

Este trabalho, desenvolvido no Colégio Técnico de Campinas (COTUCA), é um projeto de pesquisa e desenvolvimento com o objetivo de criar uma ferramenta tecnológica, o PreviDengue, para auxiliar no combate à dengue. A ferramenta integra duas inteligências artificiais: uma para identificação de criadouros e outra para previsão de casos, com o intuito de apoiar a tomada de decisão de órgãos de saúde pública.

Orientadora: Andreia Cristina de Souza

Coorientadora: Marcia Maria Tognetti Correa

CAMPINAS/SP
2025

AGRADECIMENTOS

Gostaríamos de expressar nossa sincera gratidão à nossa orientadora Prof.^a Andreia Cristina de Souza e coorientadora Prof.^a Marcia Maria Tognetti Correa pela inestimável orientação, paciência e incentivo ao longo de todo o desenvolvimento deste trabalho. A dedicação, a disponibilidade e as valiosas contribuições de ambas foram fundamentais para o amadurecimento da pesquisa e para a consolidação do projeto.

Manifestamos também um agradecimento especial ao Prof. Guilherme de Oliveira Macedo, cuja participação foi decisiva para a viabilização da ideia inicial deste trabalho ao prover o *dataset* de imagens por meio de uma parceria com a UNICAMP. Sua contribuição foi essencial para que a proposta pudesse se transformar em uma solução prática e relevante.

Reconhecemos o papel crucial que a UNICAMP e uma outra instituição, que por motivos de confidencialidade não pode ser revelada, desempenharam ao nos oferecer acesso a um banco de dados de fotos aéreas de quintais para o treinamento da inteligência artificial de detecção. Sem esses dados de alta qualidade, seria impossível desenvolver um modelo preciso.

Por fim, agradecemos ao Colégio Técnico de Campinas (COTUCA) pela oportunidade de realizar este projeto e pelo suporte acadêmico e institucional oferecido durante todo o processo.

“Não se gerencia o que não se mede, não se mede o que não se define, não se define o que não se entende, e não há sucesso no que não se gerencia.”

— William Edwards Deming

RESUMO

O combate à dengue enfrenta desafios associados à dificuldade da eliminação eficiente de criadouros e de preparação para picos da doença, que ocorrem de maneira imprevisível. Atualmente, a remoção de focos de proliferação do mosquito depende da colaboração social e de um processo lento de checagem de porta em porta pelas equipes de combate às endemias. A previsão de casos também carece de ferramentas eficientes, possuindo limitações acerca da acessibilidade das previsões e do escopo da cobertura. A fim de auxiliar na elaboração e execução de medidas eficazes de combate à dengue, este trabalho desenvolveu uma rede neural LSTM capaz de estimar futuros casos de dengue com semanas de antecedência e elaborou um modelo de algoritmo YOLO que permite a identificação dos principais focos de propagação do mosquito da dengue ao reconhecer criadouros e associá-los a domicílios. O modelo de previsão de casos se baseou em dados de ocorrência de dengue disponibilizados pelo DATASUS e dados climáticos da NASA enquanto o modelo de identificação contou com a disponibilização de fotos aéreas de domicílios em uma parceria com a UNICAMP. Esses modelos foram integrados em um painel de análise e disponibilizados em um site intitulado Previdengue, possibilitando o acesso das estimativas de casos de todas as cidades do Brasil e da ferramenta de identificação de criadouros. Dessa forma, este trabalho contribui para o desenvolvimento de ferramentas inteligentes voltadas à saúde pública ao mesmo tempo em que já oferece ferramentas com impacto social concreto, permitindo uma preparação pessoal e institucional frente a picos de dengue e oferecendo a prefeituras um modelo que torna a eliminação de criadouros mais eficiente, levando a uma diminuição no número de casos da doença a nível municipal.

Palavras-Chave: Dengue. Inteligência Artificial. Saúde Pública.

ABSTRACT

The fight against dengue faces challenges related to the difficulty of efficiently eliminating breeding sites and preparing for disease outbreaks, which occur unpredictably. Currently, the removal of mosquito proliferation sites depends on social collaboration and a slow door-to-door inspection process carried out by endemic disease control teams. Case prediction also lacks efficient tools, presenting limitations regarding accessibility and coverage scope. To assist in the planning and implementation of effective dengue control measures, this study developed an LSTM neural network capable of estimating future dengue cases several weeks in advance and created a YOLO algorithm model that allows the identification of the main mosquito breeding sites by recognizing and geographically indexing objects that offer an ideal place for mosquitoes to lay their eggs. The case prediction model was based on dengue occurrence data provided by DATASUS and climate data from NASA, while the identification model relied on aerial photographs of households made available through a partnership with UNICAMP. These models were integrated into an analysis dashboard and made accessible via a website called Previdengue, enabling access to case estimates for all cities in Brazil as well as the breeding site identification tool. Therefore, this work contributes to the development of intelligent tools for public health while already providing solutions with tangible social impact, allowing personal and institutional preparation for dengue outbreaks and equipping city halls with a model that makes breeding site elimination more efficient, ultimately reducing the number of disease cases in cities.

Key-Words: Dengue. Artificial Intelligence. Public Health.

LISTA DE ILUSTRAÇÕES

Figura 1 – Evolução dos casos semanais de dengue no Brasil (2014–2025).....	12
Figura 2 – Ciclo de vida do mosquito Aedes aegypti.....	17
Figura 3 - Interface de labelling dos criadouros.....	21
Figura 4 - Exemplos de data augmentation.....	22
Figura 5 - Página inicial do PreviDengue.....	25
Figura 6 - Página de detecção do PreviDengue.....	25
Figura 7 - Página de previsão do PreviDengue.....	26
Figura 8 - Mapa de calor do dashboard.....	27
Figura 9 - Painel de alertas e previsão de casos no dashboard.....	27
Figura 10 - Relatório gerado pelo sistema.....	28
Figura 11 - Gráfico de previsão municipal de casos de Campinas.....	31
Figura 12 - Gráfico de previsão estadual de casos de São Paulo.....	31

LISTA DE TABELAS

Tabela 1: Métricas de desempenho do modelo de detecção de criadouros.....	30
Tabela 2: Métricas de desempenho do modelo de previsão de casos.....	30

LISTA DE ABREVIATURAS E SIGLAS

API - Application Programming Interface

COTUCA - Colégio Técnico de Campinas

DATASUS - Departamento de Informática do Sistema Único de Saúde

GPU - Graphics Processing Unit

IA - Inteligência Artificial

IoU - Intersection over Union

LSTM - Long Short-Term Memory

MAE - Mean Absolute Error

mAP - mean Average Precision

NASA - National Aeronautics and Space Administration

ODS - Objetivos de Desenvolvimento Sustentável

OPAS - Organização Pan-Americana da Saúde

RMSE - Root Mean Squared Error

SUS - Sistema Único de Saúde

UNICAMP - Universidade Estadual de Campinas

YOLO - You Only Look Once

SUMÁRIO

1 INTRODUÇÃO.....	12
2 FUNDAMENTAÇÃO TEÓRICA.....	15
2.1 A dengue.....	15
2.1.1 Impacto na saúde pública.....	15
2.1.2 Criadouros e proliferação da doença.....	16
2.1.3 Ciclo de reprodução do mosquito.....	16
2.2 Inteligência artificial no combate à dengue.....	17
2.2.1 Visão Computacional para a detecção de criadouros.....	18
2.2.2 Modelo de IA para a previsão de casos.....	19
3 DESENVOLVIMENTO E METODOLOGIA.....	20
3.1 Definição do tema e planejamento inicial.....	20
3.2 Etapa de detecção de criadouros.....	21
3.2.1 Coleta e preparação das imagens.....	21
3.2.2 Treinamento e testes do sistema.....	22
3.3 Etapa de previsão de casos.....	23
3.3.1 Uso de dados históricos e climáticos.....	23
3.3.2 Construção do modelo preditivo.....	23
3.4 Construção do website.....	24
3.4.1 Página de detecção.....	25
3.4.2 Página de previsão.....	26
3.4.3 Dashboard interativo.....	26
4 CONSIDERAÇÕES FINAIS.....	29
4.1 Desempenho da ferramenta de detecção.....	29
4.2 Desempenho da ferramenta de previsão.....	30
4.3 Limitações e desafios enfrentados.....	31
4.4 Conclusão e perspectivas de continuidade.....	32
REFERÊNCIA.....	33
GLOSSÁRIO.....	34

1 INTRODUÇÃO

A dengue é uma das doenças com maior impacto na sociedade brasileira, acometendo milhões de pessoas todos os anos e gerando efeitos significativos na saúde pública e na qualidade de vida da população. Somente em 2024, foram registrados mais de 6,4 milhões de casos em todo o país, evidenciando a amplitude da doença. Além de afetar um grande número de pessoas, a dengue provoca sintomas debilitantes, como febre alta, dores musculares e articulares, dor de cabeça intensa, mal-estar e vômitos, que comprometem a capacidade dos indivíduos de realizar atividades cotidianas, incluindo trabalho e estudo. A confluência dessas duas características da doença leva a dengue a ter um impacto além do individual, uma vez que seus picos podem sobrecarregar o sistema de saúde e afetar o funcionamento de empresas de médio e pequeno porte.

Apesar da relevância da dengue, o combate à sua propagação enfrenta desafios significativos na remoção de criadouros e no preparo frente a picos da doença. Atualmente, a eliminação de focos de proliferação do mosquito *Aedes aegypti* depende principalmente da colaboração social, entretanto essa cooperação resulta na remoção incompleta de criadouros devido à aderência parcial da população e a limitações do alcance das campanhas informacionais. A fim de cobrir as lacunas na eliminação dos principais focos de reprodução do mosquito, o governo possuí equipes de fiscalização e remoção de criadouros, entretanto a atuação delas é limitada devido à ineficiência do método de visitar casas de porta em porta, o qual depende da disponibilidade dos moradores de receber os agentes e em muitas instâncias não resulta na identificação de nenhum criadouro. Paralelamente, a correta alocação de recursos em antecipação a crises da dengue é dificultada devido à imprevisibilidade dos casos da dengue decorrente do seu crescimento brusco e do início e fim súbito dos picos, como exibido na figura 1. As ferramentas atuais que propõe a produção de estimativas de casos de dengue para reduzir a imprevisibilidade dos picos apresentam limitações na sua acessibilidade e restrições no escopo da sua cobertura. A ausência de métodos eficazes na eliminação de criadouros e na previsão dos picos de casos tem um efeito sindêmico que compromete a capacidade da sociedade de enfrentar o problema da dengue.

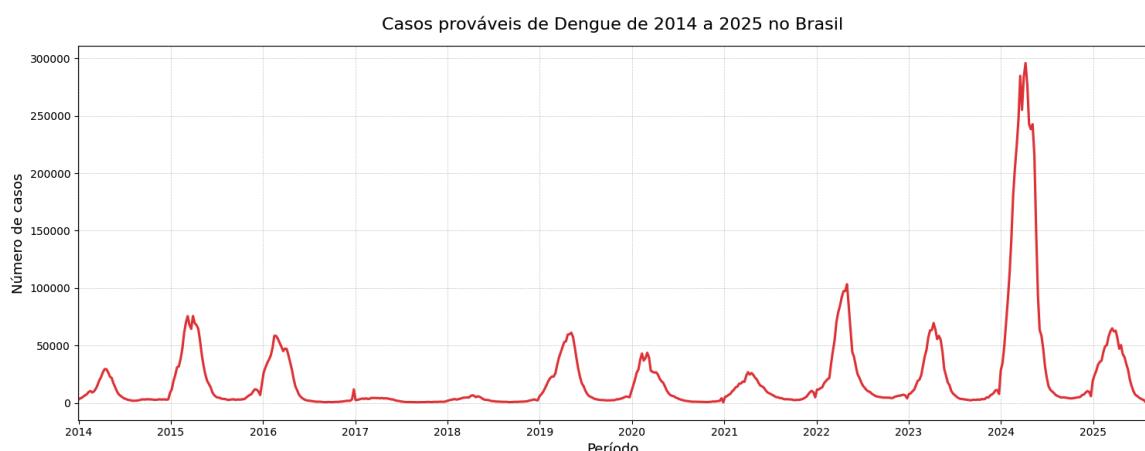


Figura 1 – Evolução dos casos semanais de dengue no Brasil (2014–2025)
Elaboração própria com base em dados do DATASUS/TABNET (2025)

Diante da ineficácia dos métodos atualmente disponíveis para a identificação de criadouros e para a previsão de picos de dengue, este trabalho propõe o desenvolvimento de duas inteligências artificiais que superem as limitações dos sistemas existentes a fim de viabilizar medidas de impacto real no combate à doença. O primeiro modelo desenvolvido é capaz de identificar e contabilizar criadouros em fotos de drones de domicílios, além de destacar sua distribuição geográfica nas imagens. Essa funcionalidade permite que uma lista de regiões com maior quantidade de criadouros seja gerada para indicar as áreas que devem ser priorizadas pelas equipes de combate às endemias, levando em conta o número e tipo de criadouros presentes. Dessa forma, essa ferramenta permite o desenvolvimento de um sistema de fiscalização e eliminação de focos de dengue muito mais eficiente do que o atual, evitando visitas em casas que não possuem criadouros, permitindo a priorização dos maiores focos e oferecendo um relatório preliminar ao agente de saúde. O segundo modelo desenvolvido é capaz de estimar o número de casos de dengue das 4 próximas semanas de qualquer cidade do Brasil com base na ocorrência recente da doença, dados climáticos e na época do ano atual. Essa funcionalidade permite que o usuário possa analisar dados concretos sobre a tendência da doença, recebendo um aviso prévio de picos de dengue e podendo visualizar a escala do surto atual. Dessa forma, essa ferramenta possibilita uma organização a nível institucional e pessoal frente a futuros picos de dengue, levando a uma diminuição do impacto direto e indireto da doença e permitindo que o indivíduo atente-se a medidas preventivas, como o uso do repelente, durante picos. O desenvolvimento simultâneo dessas duas inteligências artificiais não só permitiu a sua integração em uma plataforma única, oferecendo uma análise cruzada de seus resultados, como também permitiu que este trabalho apresentasse uma visão mais completa sobre os desafios associados à elaboração de aplicações de IA na saúde pública, assim contribuindo para o avanço teórico e metodológico desse campo de pesquisa.

O treinamento desses dois modelos ocorreu no Google Colab e seu desenvolvimento se baseou em uma abordagem iterativa na qual ajustamos os hiperparâmetros dos modelos e analisamos seus resultados (avaliando a possibilidade de *overfitting*, a precisão e a matriz de correlação) para produzir uma próxima versão refinada. A IA de detecção foi desenvolvida utilizando o algoritmo YOLO de visão computacional treinado com imagens aéreas de drones disponibilizadas por meio de uma parceria com a UNICAMP e o modelo de previsão de casos de dengue utilizou a arquitetura de rede neural LSTM com dados climáticos da NASA e de incidência de dengue por semana epidemiológica do DATASUS de todas as cidades do Brasil no período de 2014 a 2025. A fim de disponibilizar esses modelos para uso do público geral, também foi desenvolvido um site chamado Previdengue hospedado na plataforma Vercel e uma API das IAs foi publicada no Hugging Face.

Nas seções a frente, este trabalho expõe a fundamentação teórica, o processo de desenvolvimento e metodologia e as considerações finais. A primeira seção expõe o embasamento teórico que permitiu a escolha dos modelos e as informações sobre a doença que guiaram o processo de análise e desenvolvimento das IAs. A seção que aborda o desenvolvimento do trabalho destaca o caminho metodológico percorrido durante a elaboração dos modelos e do site e detalha a implementação das tecnologias utilizadas. Por último, as considerações finais destacam a relevância desse trabalho no atual contexto de

desenvolvimento de ferramentas baseadas em inteligência artificial para a saúde pública, exibem os resultados do trabalho e revelam o seu impacto.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 A dengue

A dengue é uma arbovirose transmitida pelo mosquito *Aedes aegypti*, vetor altamente adaptado ao ambiente urbano. Trata-se de uma doença de grande relevância epidemiológica, tanto pela sua ampla disseminação em países tropicais quanto pelas consequências clínicas, sociais e econômicas que acarreta. No Brasil, a dengue se consolidou como um dos maiores problemas de saúde pública, com ciclos epidêmicos recorrentes e a circulação simultânea de diferentes sorotipos virais, o que amplia a probabilidade de infecções graves e de reinfecções (Revista FT, 2023).

A transmissão da dengue não depende apenas de fatores biológicos, mas também é influenciada por fatores estruturais e governamentais, como o manejo adequado do lixo (Bezerra; Matos, 2023). Assim, compreender a doença e suas dinâmicas de transmissão é essencial para desenvolver estratégias eficazes de monitoramento e prevenção.

2.1.1 Impacto na saúde pública

Devido ao grande número de casos e à gravidade dos sintomas da dengue, essa doença cria uma demanda constante sobre os recursos do sistema de saúde público. Esse impacto toma novas proporções durante períodos de surto, nos quais o aumento expressivo de atendimentos de urgência e internações pode sobrecarregar hospitais (Revista FT, 2023). Esse estresse sobre o sistema de saúde compromete não apenas a resposta à dengue mas também a outras doenças, configurando um risco generalizado para a população.

Além do impacto sobre o sistema de saúde, os casos mais graves de dengue apresentam risco de morte aos pacientes. Quando não diagnosticada e tratada de forma adequada e antecipada, a doença pode evoluir para quadros hemorrágicos com alta letalidade (Ministério da Saúde, 2025). Esse aspecto da doença evidencia de maneira direta a gravidade do impacto da dengue na população, evidenciando a urgência de medidas públicas que combatam a doença.

A dengue também impõe danos significativos no campo econômico, levando a despesas para o governo e para empresas privadas. Os custos das medidas governamentais de combate a essa doença - como a eliminação de criadouros, mobilização de campanhas emergenciais, internações hospitalares e aquisição de insumos - consomem uma parcela razoável do orçamento da saúde pública. Além disso, as empresas enfrentam perdas relacionadas ao

afastamento de trabalhadores doentes e à diminuição da produtividade em períodos de surto (TEICH; ARINELLI; FAHHAM, 2018). Nesse contexto, a literatura aponta que medidas preventivas apresentam um maior custo benefício, podendo levar a uma redução em despesas diretas, como os gastos em tratamentos, e indiretas, como aquelas associadas ao estresse do sistema de saúde e à perda de produtividade.

2.1.2 Criadouros e proliferação da doença

A categorização e o estudo dos criadouros do mosquito *Aedes aegypti* é fundamental para o controle da dengue, uma vez que esses ambientes são vitais para o ciclo reprodutivo desse mosquito. Diferente de outros vetores que se limitam principalmente a ecossistemas naturais, o *Aedes aegypti* é altamente adaptado ao ambiente urbano e explora preferencialmente recipientes artificiais que acumulam água limpa ou pouco poluída (Bezerra; Matos, 2023).

Estudos de vigilância entomológica apontam que mesmo pequenos recipientes, como tampinhas de garrafa, vasos de plantas ou ralos, podem gerar milhares de mosquitos ao longo de uma temporada de reprodução devido à elevada taxa de sobrevivência das larvas (Wermelinger et al., 2012). Além disso, recipientes maiores, como caixas-d'água mal vedadas, piscinas sem manutenção e calhas entupidas, apresentam grande potencial de proliferação por oferecerem condições estáveis e contínuas para o desenvolvimento do inseto.

Essa diversidade de criadouros torna o combate ao mosquito um desafio constante. A eliminação manual de focos, embora essencial, depende de uma mobilização social abrangente e contínua complementada pelo trabalho de equipes do governo, o qual ainda carece de ferramentas que o tornem mais eficiente. É nesse contexto que se percebe o potencial impacto de tecnologias de fiscalização automática, como a ferramenta de visão computacional proposta pelo Previdengue, no combate à proliferação da doença e na otimização do uso de recursos estatais.

2.1.3 Ciclo de reprodução do mosquito

O ciclo de vida do *Aedes aegypti* (figura 2) é um dos principais fatores que explicam a rapidez da disseminação da dengue. Ele se divide em quatro fases: ovo, larva, pupa e adulto, podendo ser completado em apenas 7 a 10 dias em condições ambientais favoráveis de calor e umidade (Ministério da Saúde, 2025).

Essa velocidade no ciclo reprodutivo somada à resistência dos ovos - que podem resistir por meses em superfícies secas - representa um grande desafio para o controle da doença, uma vez que um único recipiente com água parada pode, em poucos dias, se transformar em um foco de centenas de mosquitos (Prefeitura de São Paulo, 2024). Dessa forma, o combate aos criadouros deve ser completo a fim de não permitir que poucos repositórios de água levem a uma endemia.

A capacidade de larvas sobreviverem até a fase adulta é especialmente relevante para a saúde pública, uma vez que é apenas nesse estágio em que as fêmeas começam a buscar sangue para maturar seus ovos. Como uma única fêmea pode contaminar dezenas de pessoas ao longo da sua vida e uma única postura é capaz de resultar em dezenas de adultos, o ciclo de vida do mosquito o torna um vetor com alta capacidade infecciosa, amplificando a transmissão do vírus da dengue.



Figura 2 – Ciclo de vida do mosquito *Aedes aegypti*
Fonte: Milenne Souza de Lima / CIEVS/RS

2.2 Inteligência artificial no combate à dengue

O emprego da Inteligência Artificial (IA) no combate à dengue apresenta um grande potencial de transformar as práticas de vigilância epidemiológica e administração frente a picos de casos, tornando possível o desenvolvimento de ferramentas e métodos mais eficientes do que os atuais. Tradicionalmente, a prevenção de casos de dengue conta com um trabalho de

eliminação de criadouros realizado por agentes de saúde, entretanto essa atividade tem caráter predominantemente remediativo: as equipes percorrem bairros, visitam residências de porta em porta e eliminam manualmente os criadouros detectados apenas após a identificação da região como um foco de proliferação devido a um aumento na ocorrência de casos. Esse processo, além de dispendioso e demorado, resulta em múltiplas visitas a casas com poucos ou nenhum criadouro, levando a uma baixa cobertura territorial e ineficiência, o que é principalmente problemático em momentos de maior incidência (OPAS, 2023). Além disso, a imprevisibilidade dos surtos da doença impede, entre outras medidas, que as equipes de remoção de criadouros sejam mobilizadas antes que uma região se torne um foco de proliferação do mosquito.

Com a utilização de IA, propõe-se uma abordagem proativa e automatizada, capaz de auxiliar diretamente os agentes de saúde na priorização de áreas de risco, reduzindo desperdícios de recursos e aumentando a efetividade das campanhas. Ao identificar possíveis criadouros em imagens aéreas, a IA de identificação torna viável o levantamento de áreas propícias à proliferação do mosquito, eliminando a necessidade de esperar que um aumento do número de casos as indique. Além disso, a previsão de futuros surtos pode destacar os momentos mais urgentes para a remoção de criadouros, uma vez que um crescimento no número de casos das próximas semanas pode ser fruto de um aumento na reprodução do mosquito na semana atual. (ZHANG et al., 2020).

2.2.1 Visão Computacional para a detecção de criadouros

A visão computacional, ramo da IA voltado à interpretação de imagens, tem sido aplicada com sucesso na identificação de criadouros do *Aedes aegypti*. A partir de imagens aéreas obtidas por drones ou satélites, algoritmos de detecção de objetos, como o algoritmo YOLO (You Only Look Once), permitem localizar estruturas e objetos associadas à proliferação do mosquito, como piscinas descobertas, caixas-d'água e depósitos de resíduos (Redmon et al., 2016).

A velocidade dessa tecnologia na identificação de objetos a torna ideal para trabalhos relacionados ao levantamento estatístico de grandes conjuntos de imagens, sendo capaz de descartar fotos que não contenham objetos de interesse e destacar estes nas fotos que os contém. . Estudos demonstram que tais algoritmos alcançam alta precisão na classificação de objetos, mesmo em conjuntos de dados complexos, como o de identificação de criadouros de dengue (Albawi; Mohammed; Al-Zawi, 2017).

2.2.2 Modelo de IA para a previsão de casos

Modelos baseados em aprendizado de máquina e redes neurais recorrentes, como a LSTM (Long Short-Term Memory), têm sido utilizados para analisar séries temporais de casos notificados, incorporando variáveis ambientais como temperatura, precipitação, umidade e insolação (Hochreiter; Schmidhuber, 1997).

Pesquisas recentes evidenciam que modelos preditivos podem antecipar com razoável acurácia o aumento do número de casos de doenças em determinada localidade, permitindo que órgãos de saúde mobilizem recursos preventivos antes da ocorrência de picos epidêmicos (Zhang et al., 2020). Essa capacidade preditiva é essencial para garantir um combate eficiente da dengue e evitar mortes.

3 DESENVOLVIMENTO E METODOLOGIA

3.1 Definição do tema e planejamento inicial

A escolha do tema partiu do interesse de alinhar o desenvolvimento de IAs a um problema de relevância social e de impacto direto na saúde pública. Entre as diversas possibilidades de aplicação da Inteligência Artificial, identificou-se o combate à proliferação da dengue como objetivo em função da alta incidência dessa doença no Brasil, dos prejuízos humanos e econômicos decorrentes dos surtos e do alinhamento dessa meta com os Objetivos de Desenvolvimento Sustentável (ODS).

O desenvolvimento de um modelo de detecção de criadouros foi possibilitado por diversas pesquisas acadêmicas anteriores e por um projeto colaborativo em andamento entre a Universidade Estadual de Campinas (Unicamp) e uma segunda instituição confidencial, que investiga o uso de visão computacional para identificação de focos do *Aedes aegypti* a partir de imagens aéreas urbanas. Esse projeto viabilizou a proposta ao fornecer acesso a imagens aéreas de áreas residenciais, o qual foi fundamental para o treinamento do modelo de detecção.

Já o desenvolvimento do modelo de predição de casos de dengue foi possibilitado pelos dados de incidência de dengue do DATASUS e pesquisas sobre a reprodução do mosquito. Essas informações foram essenciais para a elaboração da IA, fornecendo os dados necessários para treiná-la e embasando nossa análise sobre seu funcionamento.

Com base nessas referências, o planejamento inicial foi estruturado em duas frentes complementares:

1. **Detecção de potenciais criadouros** em imagens aéreas utilizando algoritmos de visão computacional;
2. **Previsão de casos de dengue** por meio de modelos de aprendizado de máquina aplicados a séries históricas epidemiológicas e variáveis climáticas.

A realização desse projeto foi orientada por um planejamento inicial, que identificou as etapas necessárias para a elaboração dos modelos e estipulou o cronograma para a conclusão dos requerimentos do projeto.. A fim de escolher os modelos a serem utilizados, adotamos uma abordagem que uniu a revisão da bibliografia à realização de testes empíricos com diferentes algoritmos de visão computacional e modelos preditivos de séries temporais, avaliando sua

aplicabilidade ao problema. Também foram analisadas soluções já existentes para a vigilância da dengue a fim de se basear na pesquisa já elaborada sobre o desenvolvimento de IAs para esse fim e identificar como a nossa ferramenta poderia complementar o trabalho atualmente realizado pelas equipes de combate às endemias. Essa abordagem inicial baseada na combinação da revisão da literatura e na experimentação prática norteou a metodologia aplicada ao resto do desenvolvimento do projeto.

3.2 Etapa de detecção de criadouros

3.2.1 Coleta e preparação das imagens

O conjunto inicial de dados foi composto por fotografias aéreas de quintais residenciais. Para que essas imagens pudessem ser utilizadas em modelos de detecção de imagens, foi realizado um processo de rotulagem manual (*labelling*), no qual cada piscina, caixa-d'água, pneus, entulhos e outros elementos de interesse foram marcados e classificados com a ferramenta *makesense*, como visto abaixo na figura 3.



Figura 3 - Interface de *labelling* dos criadouros

Como a quantidade de imagens disponíveis era limitada, aplicaram-se técnicas de aumento artificial de dados (*data augmentation*), como visto na figura 4, que consistem em criar versões modificadas das imagens originais a fim de ampliar a diversidade e o tamanho do conjunto de dados. Foram utilizadas variações como ajuste de brilho e cor, adição de ruído,

borramento e alterações de contraste. Esse procedimento é amplamente adotado em visão computacional porque ajuda a reduzir o risco de que a rede “decore” apenas os exemplos apresentados, melhorando assim sua capacidade de reconhecer padrões em novas imagens (Albawi; Mohammed; Al-Zawi, 2017).

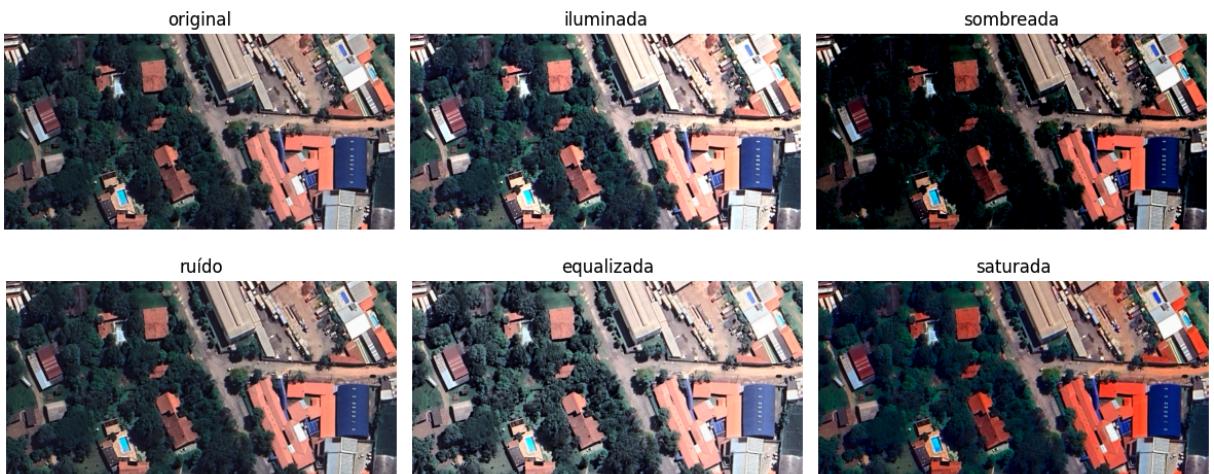


Figura 4 - Exemplos de *data augmentation*

3.2.2 Treinamento e testes do sistema

Para a detecção dos criadouros, foi utilizado o modelo YOLO, conhecido por combinar rapidez e precisão na identificação de objetos em imagens (Redmon et al., 2016). O treinamento do modelo foi realizado em um ambiente de nuvem no Google Colab, uma vez que os recursos computacionais locais não seriam suficientes para essa tarefa.

Durante o treinamento, aplicaram-se técnicas de otimização, como o *early stopping*, que consiste em interromper automaticamente o processo quando não há melhora significativa no desempenho. Isso evita que a rede “exagere” no aprendizado e se torne menos eficaz em novos conjuntos de imagens (Goodfellow; Bengio; Courville, 2016). As fotos foram divididas em duas partes: um conjunto para o aprendizado da rede (treinamento) e outro para verificar o desempenho final (teste).

A avaliação do modelo foi feita com base em diferentes métricas de desempenho: precisão (quantos dos objetos identificados estavam corretos), revocação (*recall*, proporção de objetos que o modelo conseguiu encontrar) e mAP (*mean Average Precision*, uma média geral da acurácia). Essas métricas são amplamente utilizadas na área de visão computacional e permitiram verificar não apenas a exatidão das previsões, mas também a viabilidade prática da aplicação em cenários reais de monitoramento urbano (Zhang et al., 2020).

Além das otimizações mencionadas, foi implementada uma técnica de hard negative mining (mineração de negativos difíceis) durante a etapa de ajuste fino do modelo. Ao longo do desenvolvimento do modelo, foi identificado que objetos normais estavam sendo incorretamente classificados pelo sistema como criadouros, gerando falsos positivos. Para resolver esse problema, imagens específicas, que continham objetos ou fundos visualmente semelhantes aos criadouros, foram incorporadas ao conjunto de treinamento. O objetivo dessa realimentação foi aprimorar a capacidade de discernimento do modelo, forçando-o a aprender características mais robustas e a reduzir significativamente a taxa de detecções incorretas, o que é crucial para a precisão da aplicação em campo.

3.3 Etapa de previsão de casos

O objetivo desta etapa foi desenvolver um modelo preditivo capaz de estimar o número de casos de dengue com um horizonte de seis semanas com base em dados históricos da doença e informações climáticas. A proposta fundamenta-se em estudos que apontam a forte influência de fatores ambientais sobre a dinâmica de transmissão da dengue e pesquisas prévias sobre a aplicação de modelos de aprendizado profundo para séries temporais (Hochreiter; Schmidhuber, 1997; Guo et al., 2019).

3.3.1 Uso de dados históricos e climáticos

A base de dados epidemiológicos utilizada foi o DATASUS, por meio da plataforma TABNET, que reúne registros semanais de casos confirmados de dengue em todo o Brasil desde 2014, discriminados por município de infecção. Esses dados, além de cobrirem um período longo - permitindo a análise de padrões recorrentes e garantindo uma grande quantidade de dados -, possuem granularidade espacial e temporal adequada para subsidiar modelos de previsão a um nível municipal..

Como complemento, foram incorporadas variáveis ambientais provenientes da NASA POWER API, que disponibiliza informações meteorológicas derivadas de satélites. Para cada município, com base em suas coordenadas geográficas, foram coletados indicadores de temperatura média, mínima e máxima; precipitação total; umidade relativa; e radiação solar incidente. Como os fatores ambientais estão diretamente relacionados à taxa de reprodução do mosquito, a presença dessas informações no *dataset* é essencial para garantir uma maior precisão e confiabilidade na previsão dos casos.

Aqui está uma sugestão para o parágrafo, mantendo a coesão e o tom técnico dos anteriores:

Para viabilizar as previsões em nível estadual, foi necessário um processo de agregação dos dados municipais. Para isso, os casos de dengue de cada cidade foram somados para obter o total de seus estados, enquanto as variáveis ambientais foram tratadas por meio de uma média ponderada pela população de cada município. Essa abordagem metodológica garante que as condições ambientais de municípios mais populosos, que concentram a maior parte da população e, consequentemente, influenciam mais fortemente os registros epidemiológicos estaduais, tenham um peso proporcionalmente adequado no conjunto de dados agregado.

3.3.2 Construção do modelo preditivo

O modelo de previsão foi desenvolvido com base em redes neurais recorrentes do tipo LSTM, adequadas para lidar com dependências temporais de longo alcance. Para cada município, a rede recebe como entrada os dados das semanas anteriores de casos e condições climáticas e produz como saída a previsão para as seis semanas seguintes. Como os dados de casos de dengue do DATASUS tem um período de duas semanas com informações parcialmente atualizadas, é necessário descartar essas semanas para que o modelo não seja influenciado pela subnotificação. Portanto, das seis semanas previstas, duas são de semanas já decorridas.

A função de perda utilizada foi uma versão modificada do erro quadrático médio, denominada *asymmetric_mse*. Essa função penaliza de forma mais intensa os erros de subestimação, uma vez que a subestimação dos casos pode acarretar em consequências mais graves do que falsos alertas.. Além disso, foram implementados mecanismos de *early stopping* com base em uma métrica ponderada por município (*city_val_loss*), que considerava o peso epidemiológico de cada localidade no cálculo da perda.

O treinamento foi realizado em ambiente de nuvem no Google Colab, utilizando recursos de GPU para lidar com a complexidade dos modelos e a grande quantidade de dados. O conjunto de séries temporais foi dividido em treino e teste, respeitando a ordem cronológica para garantir condições realistas de previsão. A extração das métricas das IAs e a análise do seu desempenho foi também realizada nessa plataforma, permitindo averiguar se o modelo apresentava *overfitting* e garantir que ele atingisse uma boa precisão.

3.4 Construção do website

Com o objetivo de tornar os modelos desenvolvidos acessíveis e facilitar sua utilização por gestores de saúde, pesquisadores e pela população geral, foi construída uma plataforma *web*. Esta aplicação é composta por um website (Figura 5) publicamente disponível em previdengue.vercel.app, que serve como interface *frontend*, e uma API dedicada, disponível em previdengue-previdengueapi.hf.space, que funciona como o *backend*. A disponibilização dessa API permite que o site integre as funcionalidades das IAs em uma interface intuitiva e interativa.

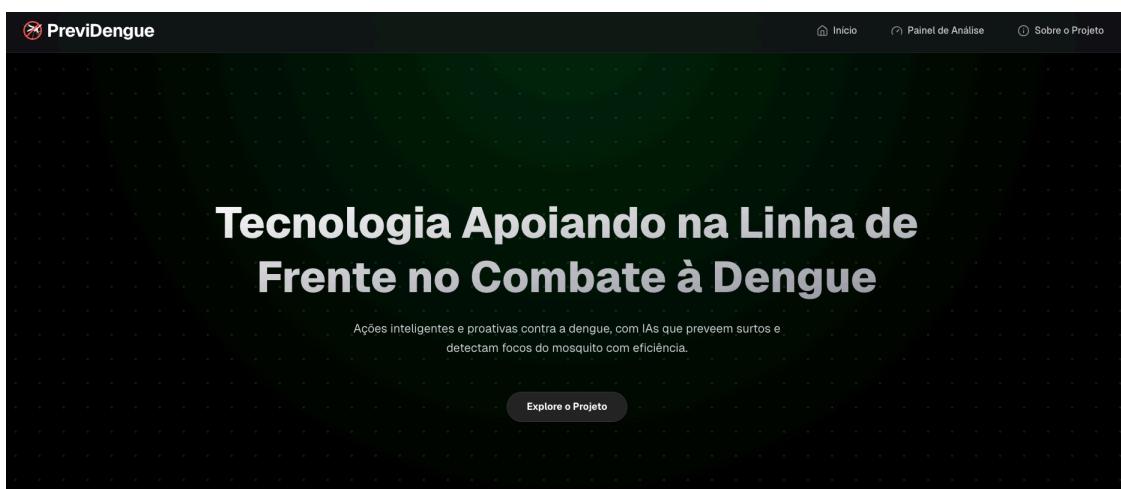


Figura 5 - Página inicial do PrevIDengue

3.4.1 Página de detecção

Na página de detecção, o usuário pode enviar imagens de quintais ou áreas urbanas para que o sistema as analise utilizando o modelo de visão computacional YOLO. O processamento identifica potenciais criadouros do *Aedes aegypti*, como piscinas e caixas-d'água, marcando os elementos diretamente sobre a imagem. O resultado é exibido em uma lista e desenhado sobre a imagem fornecida, facilitando a sua análise (Figura 6).

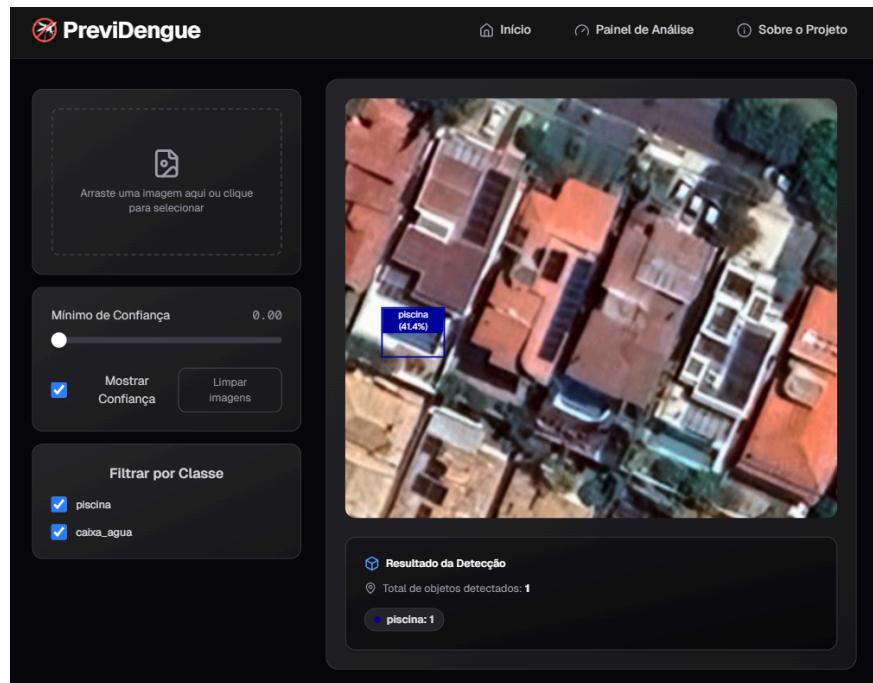


Figura 6 - Página de detecção do PreviDengue

3.4.2 Página de previsão

Na seção de previsão, é possível selecionar qualquer município brasileiro e visualizar as estimativas de casos de dengue para as semanas subsequentes. Os resultados são apresentados em gráficos claros, que destacam tendências de crescimento, estabilidade ou queda na incidência. Essa funcionalidade é alimentada pelo modelo LSTM descrito anteriormente e permite que mesmo usuários não especializados compreendam o comportamento esperado da doença (Figura 7).

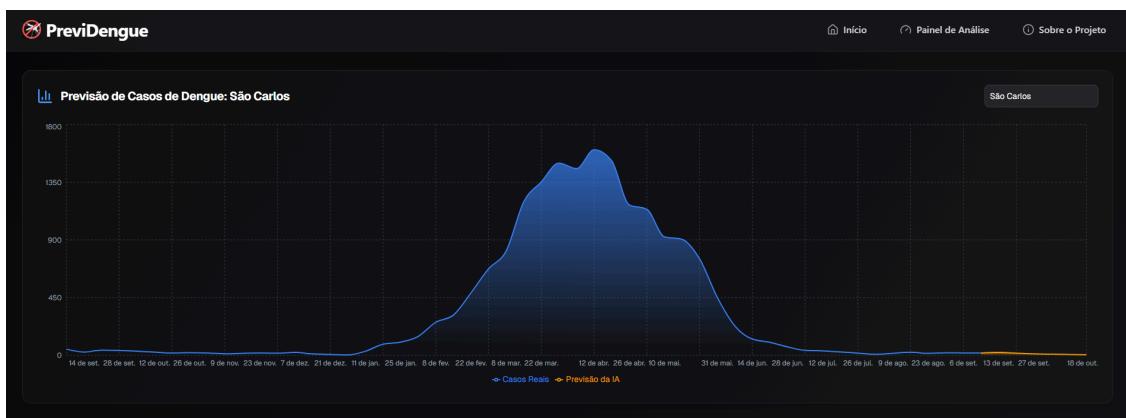


Figura 7 - Página de previsão do PreviDengue

3.4.3 Dashboard interativo

O dashboard representa a integração das principais funcionalidades em um único painel, fornecendo ao usuário uma visão abrangente da situação epidemiológica e ambiental.

A primeira parte do dashboard é o mapa de calor, que mostra espacialmente os pontos de risco associados às imagens enviadas. Ao clicar em cada ponto, o usuário pode visualizar a foto correspondente e a intensidade de risco estimada pelo sistema, em uma escala de 0 a 10, conforme ilustrado na Figura 8.

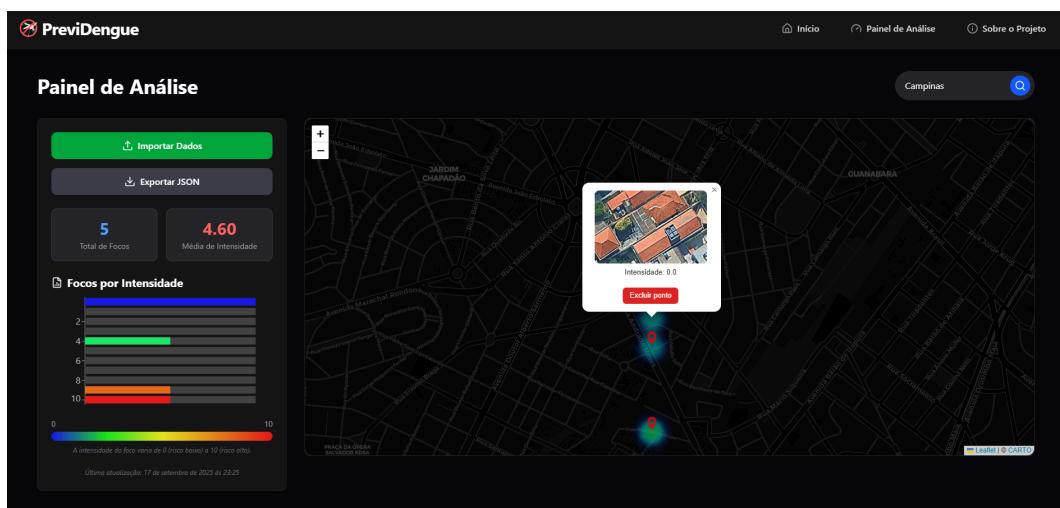


Figura 8 - Mapa de calor do dashboard

Na sequência, o dashboard apresenta o painel de alertas e previsão, que reúne informações interpretadas pelo modelo de IA, como a tendência de casos na região e a necessidade de ações pelos agentes de saúde. Esse painel também contém os gráficos da previsão de casos de dengue, que mostram a evolução histórica e a projeção para as semanas seguintes, conforme pode ser observado na Figura 9.

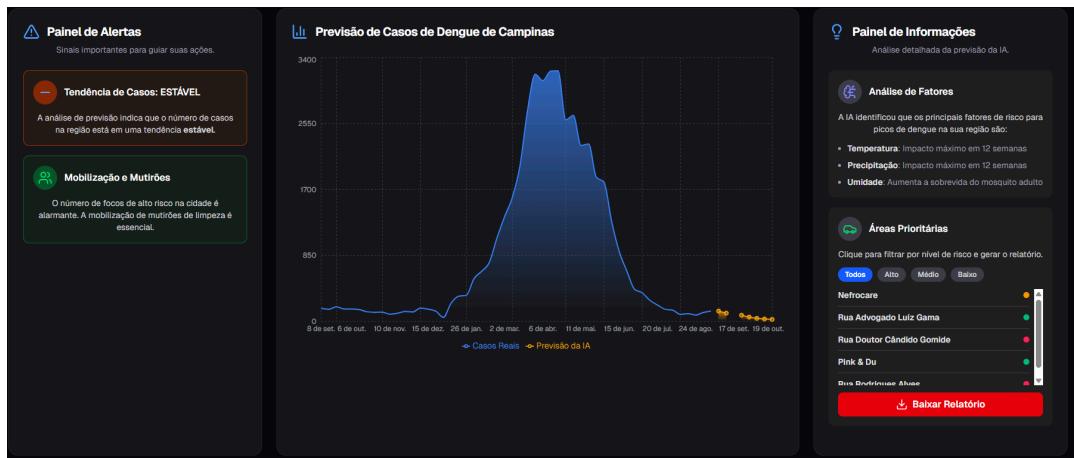


Figura 9 - Painel de alertas e previsão de casos no dashboard

Por fim, há a funcionalidade de emissão de relatórios, que organiza os dados em listas de áreas prioritárias e sugere rotas para agentes de saúde. Esse recurso torna o sistema aplicável de forma prática no planejamento das ações de vigilância ao traduzir as análises da IA em um plano de ação direto, permitindo aos gestores alocar equipes de forma otimizada e focar os esforços nas áreas de maior risco, conforme exemplificado na Figura 10.

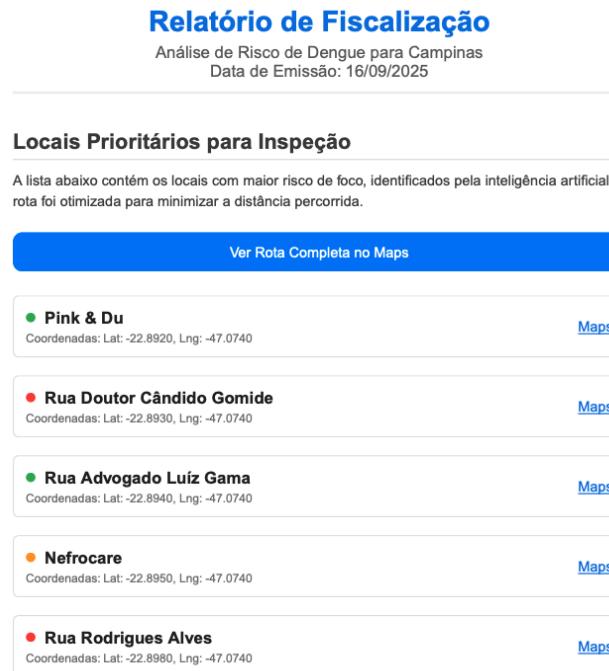


Figura 10 - Relatório gerado pelo sistema

4 CONSIDERAÇÕES FINAIS

O objetivo geral deste projeto foi desenvolver ferramentas baseadas em Inteligência Artificial para viabilizar medidas preventivas eficazes contra a dengue. Esse objetivo foi alcançado por meio do desenvolvimento de modelos de identificação de criadouros em imagens aéreas e de previsão de picos da doença. A disponibilização dessas ferramentas de maneira aberta em um site e uma API permite que os modelos desenvolvidos sejam implementados e acessados, possibilitando um impacto concreto imediato. O desenvolvimento da pesquisa exposta neste documento também auxilia o avanço do campo de pesquisa dedicado ao estudo da implementação de IAs na saúde pública.

4.1 Desempenho da ferramenta de detecção

A ferramenta de detecção de criadouros, baseada no modelo YOLO, demonstrou desempenho satisfatório ao identificar elementos como piscinas, caixas-d'água e acúmulo de entulhos em imagens aéreas. Esse resultado demonstra que sua utilização na identificação de focos de dengue para auxílio das equipes de eliminação de criadouros pode ter impacto real. Ainda que o conjunto inicial de imagens tenha sido limitado, o uso de técnicas de *data augmentation* e *early stopping* contribuíram para aumentar a diversidade e reduzir o risco de *overfitting*.

Os testes evidenciaram que o modelo foi capaz de generalizar para novas imagens, apresentando valores adequados de precisão, revocação e mAP. Conforme apresentado na tabela 1, esses resultados corroboram a literatura sobre a aplicabilidade de redes convolucionais em cenários de vigilância ambiental, confirmando o potencial do uso dessa tecnologia para fins de fiscalização não só contidos à identificação de criadouros de dengue. Considerando que houve uma limitação no tamanho do conjunto de dados para o treinamento e teste do modelo, existe ainda uma possibilidade de desenvolvimento de um modelo de maior precisão e acurácia..

Classe	Mean Precision	Mean Recall	MAP50	MAP50-95
Geral	0,792	0,683	0,773	0,562
Piscina limpa	0,555	0,786	0,795	0,65
Piscina suja	0,84	0,75	0,857	0,753
Lona	0,893	0,745	0,865	0,682

Monte de lixo	0,771	0,673	0,741	0,551
Reservatório de água	0,87	0,571	0,671	0,425
Pneu	0,826	0,828	0,872	0,493
Saco de lixo	0,789	0,427	0,608	0,376

Tabela 1: Métricas de desempenho do modelo de detecção de criadouros

4.2 Desempenho da ferramenta de previsão

A ferramenta de previsão apresentou maior complexidade de desenvolvimento, sobretudo em função da necessidade de formatar séries históricas extensas e de integrar variáveis climáticas aos registros epidemiológicos. Porém, o modelo baseado na arquitetura LSTM conseguiu antecipar tendências de crescimento e queda nos casos de dengue.

A adoção da função de perda assimétrica se mostrou adequada, pois reduziu a incidência de subestimações, o que é crítico em cenários de saúde pública. Embora a previsão de surtos de dengue seja um desafio reconhecido, os experimentos mostraram que o modelo foi capaz de oferecer estimativas consistentes, com média de erros dentro de limites aceitáveis para uso em estratégias preventivas, conforme visto na tabela 2. A integração dessa ferramenta ao website, com atualização automática a partir de novas notificações e dados climáticos, permite que ela já seja utilizada, garantindo seu impacto concreto.

Modelo	RMSE	MAE
Municipal	10,358	81,429
Estadual	706,295	4386,002

Tabela 2: Métricas de desempenho do modelo de previsão de casos

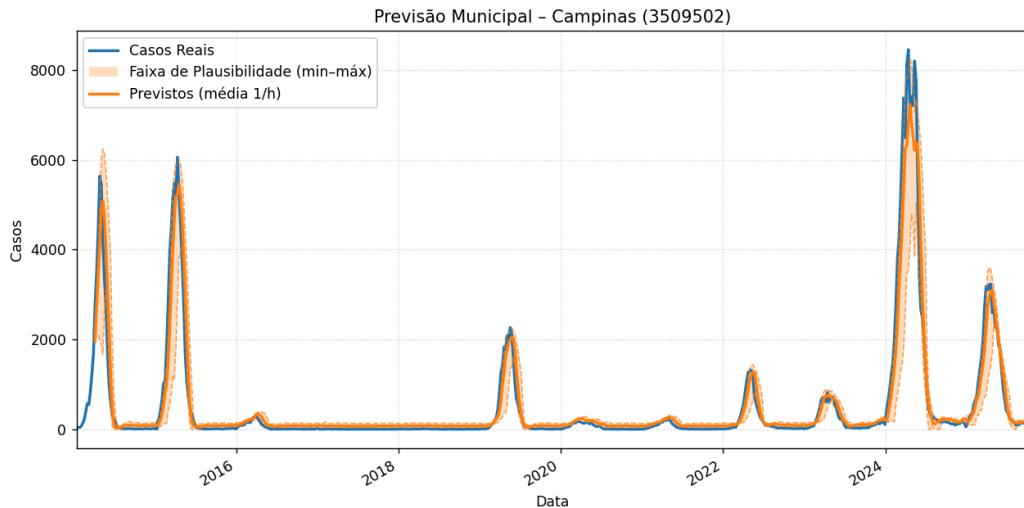


Figura 11 - Gráfico de previsão municipal de casos de Campinas

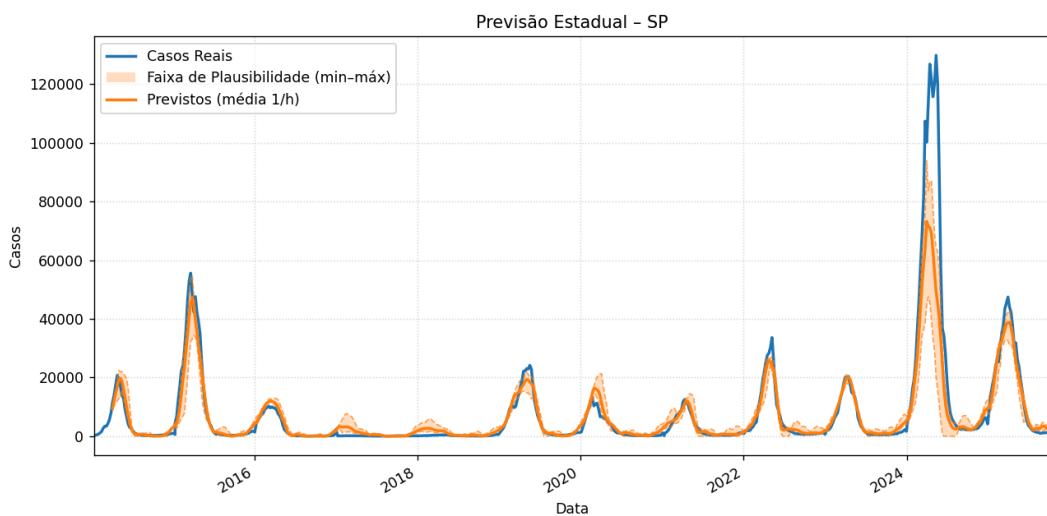


Figura 12 - Gráfico de previsão estadual de casos de São Paulo

4.3 Limitações e desafios enfrentados

O desenvolvimento contou com a resolução de obstáculos significativos. Na frente de detecção, a principal limitação foi a disponibilidade reduzida de imagens aéreas de ambientes urbanos com qualidade suficiente para identificar a maioria dos criadouros, o que restringiu o tamanho do conjunto de dados, limitando a precisão e capacidade de generalização da IA. Ainda assim, as técnicas de aumento de dados e a grande riqueza das imagens fornecidas, tanto em número de criadouros por foto quanto em diversidade, minimizaram essa carência. Na frente de previsão, os desafios foram ainda maiores. Além da necessidade de organizar e padronizar os dados epidemiológicos e climáticos, a previsão de surtos é dificultada pela natureza incerta inerente ao próprio fenômeno, marcado por múltiplos fatores ambientais,

sociais e biológicos. Essa complexidade exigiu ajustes metodológicos contínuos, como o uso de escalonadores globais e métricas de validação específicas por município.

Outro desafio foi a integração dos modelos ao website, que demandou atenção não apenas à parte técnica, mas também à experiência do usuário. Tornar o sistema acessível, visualmente claro e interativo foi essencial para garantir sua aplicabilidade em contextos de uso real.

4.4 Conclusão e perspectivas de continuidade

Os resultados obtidos demonstram a efetividade das inteligências artificiais desenvolvidas, validando a proposta e confirmando que os modelos são capazes tanto de identificar criadouros de dengue em imagens aéreas quanto de estimar o surgimento de picos de casos da doença. Esse desempenho consistente indica a solidez dos dados apresentados na plataforma desenvolvida, embasando a sua utilização no combate à proliferação do mosquito e no fornecimento de um aviso prévio sobre futuros picos de dengue. Além disso, a capacidade do modelo de detecção de identificar criadouros garante a viabilidade da sua utilização por prefeituras municipais, permitindo a elaboração de uma nova metodologia de eliminação de focos da doença de grande eficiência. O impacto da plataforma é potencializado pela sua arquitetura, que automaticamente realiza o levantamento das regiões mais críticas para a proliferação do mosquito da dengue e exibe a previsão do número de casos da região para que se avalie a urgência da remoção dos criadouros.

A efetividade prática dos modelos desenvolvidos corrobora a pesquisa já preexistente e confirma a viabilidade do desenvolvimento de IAs para a identificação de criadouros em imagens aéreas e para a previsão de casos a fim do preparo para surtos. Apesar dos bons resultados obtidos por este trabalho, aponta-se a possibilidade de aprimoramento das IAs propostas. O modelo de identificação poderia se beneficiar da inclusão de classes específicas para criadouro menores - como latinhas, garrafas PET e ralos - o que só seria possível com o aumento da resolução das imagens. Já o modelo de previsão seria beneficiado pela expansão do seu horizonte de previsão, o que auxiliaria a mobilização de ações preventivas antecipadas e de maior escala; pelo aumento na precisão do número de casos previstos, o que melhor quantificaria a escala dos surtos identificados; e pela melhora da acurácia, diminuindo o número de surtos não identificados com antecedência e levando a uma redução de falsos positivos, que ferem a confiança na IA, fazendo com que avisos reais sejam ignorados. Também seria interessante aplicar modelos explicativos na IA de previsão, o que permitiria analisar padrões dos casos de dengue e aferir a confiabilidade da previsão. No quesito da

aplicação dos modelos para uso prático, projeta-se que a UNICAMP e a outra instituição continuem com o desenvolvimento da IA de identificação, agregando um sistema para elaborar rotas para as equipes de combate às endemias priorizando os pontos mais críticos. Além disso, essa ferramenta poderia contar com a delimitação das áreas de cada domicílio, permitindo uma identificação mais precisa dos focos de dengue e auxiliando o processo de visita das equipes.

REFERÊNCIA

- ABNT. Associação Brasileira de Normas e Técnicas. NBR 14724:2005. Rio de Janeiro. 2002
- ALBAWI, S.; MOHAMMED, T. A.; AL-ZAWI, S. Understanding of a convolutional neural network. *2017 International Conference on Engineering and Technology (ICET)*, Antalya, 2017. p. 1–6. DOI: 10.1109/ICEngTechnol.2017.8308186.
- BEZERRA, T. M.; MATOS, C. C. Dengue no Brasil: fatores socioambientais associados à prevalência de casos. *Arquivos de Ciências da Saúde da UNIPAR*, Umuarama, v. 27, n. 5, p. 2685–2698, 2023.
- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. Deep Learning. Cambridge: MIT Press, 2016.
- HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. *Neural Computation*, v. 9, n. 8, p. 1735–1780, 1997.
- MINISTÉRIO DA SAÚDE (Brasil). Ciclo de vida de Aedes aegypti: do ovo ao adulto – quanto tempo temos para agir? Brasília, 2025.
- OPAS – ORGANIZAÇÃO PAN-AMERICANA DA SAÚDE. Alerta epidemiológico: aumento de casos de dengue e outras arboviroses nas Américas. Washington, DC: OPAS, 2023.
- PREFEITURA DE SÃO PAULO. Conheça as características do mosquito Aedes aegypti. São Paulo, 2024. Disponível em: <https://www.prefeitura.sp.gov.br>. Acesso em: 17 set. 2025.
- REDMON, J. et al. You Only Look Once: Unified, Real-Time Object Detection. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, Las Vegas, 2016. p. 779–788. DOI: 10.1109/CVPR.2016.91.
- REVISTA FT. Epidemiologia da dengue e seus impactos na saúde pública: uma revisão narrativa. *Revista FT Saúde*, São Paulo, v. 10, n. 2, 2023.
- TEICH, Vanessa; ARINELLI, Roberta; FAHHAM, Lucas. Aedes aegypti e sociedade: o impacto econômico das arboviroses no Brasil = *Aedes aegypti and society: the economic burden of arboviruses in Brazil*. *Journal of Business and Environmental Studies*, v. 9, n. 3, p. 267–276, 2018. DOI: 10.21115/JBES.v9.n3.p267-76.
- SEVERINO, Antonio Joaquim. Metodologia do trabalho científico. 23. ed. São Paulo: Cortez, 2007.
- WERMELINGER, E. D. et al. Avaliação da produtividade dos criadouros do Aedes aegypti (L.) e Aedes albopictus (Skuse) através dos dados da vigilância em Parati – RJ. *EntomoBrasilis*, v. 5, n. 3, p. 223-236, 2012.
- ZHANG, Y. et al. Application of artificial intelligence in the prediction of dengue fever outbreaks: A systematic review. *International Journal of Environmental Research and Public Health*, v. 17, n. 2, 2020.

GLOSSÁRIO

API: conjunto de regras que permite que diferentes softwares se comuniquem entre si, trocando dados e funcionalidades de forma padronizada.

Backend: componente do sistema que opera no servidor, responsável por processar as requisições, executar a lógica de negócio (como os modelos de IA) e enviar os resultados para o frontend.

Dashboard: painel interativo que apresenta dados de forma visual (gráficos, mapas, tabelas) para facilitar a análise e tomada de decisão.

DATASUS: base oficial de dados de saúde pública do Brasil, que reúne informações sobre doenças, internações, atendimentos e estatísticas do SUS.

Deep Learning (Aprendizado Profundo): subárea do aprendizado de máquina que utiliza redes neurais artificiais com várias camadas, capaz de extrair automaticamente padrões complexos de grandes volumes de dados.

Early Stopping: técnica que interrompe o treinamento da rede neural quando não há melhora significativa no desempenho em dados de validação, evitando o overfitting.

Escalonadores globais: técnicas de normalização de dados que ajustam diferentes variáveis para uma mesma escala numérica, permitindo que informações com magnitudes distintas (como número de casos e temperatura) possam ser comparadas.

Frontend: componente do sistema referente à interface do usuário. É responsável por exibir visualmente os dados e capturar as interações do usuário, enviando requisições para o backend.

GPU: processador especializado em cálculos matemáticos complexos, muito usado para treinar modelos de inteligência artificial.

Hiperparâmetros: parâmetros definidos antes do treinamento de um modelo de aprendizado de máquina (como taxa de aprendizado, número de camadas ou épocas), que influenciam diretamente o desempenho e a precisão do modelo.

IoU: métrica usada em visão computacional que mede a sobreposição entre o objeto real e a área detectada pelo modelo.

LSTM: tipo de rede neural artificial projetada para aprender e prever dados em sequência, como séries temporais (ex.: evolução de casos de dengue ao longo do tempo).

Machine Learning (Aprendizado de Máquina): área da inteligência artificial que desenvolve algoritmos capazes de aprender padrões a partir de dados e melhorar seu desempenho sem programação explícita.

MAE: métrica que representa a média das diferenças entre os valores previstos e os reais.

mAP50-95: métrica de avaliação mais rigorosa que calcula a média da precisão (mAP) em múltiplos níveis de exigência, com sobreposições (IoU) variando de 50% a 95%.

mAP50: métrica que avalia a precisão geral (mAP) de um modelo de detecção, considerando um acerto quando a sobreposição (IoU) entre a previsão e o objeto real é de, no mínimo, 50%.

mAP: métrica que avalia a precisão geral de um modelo de visão computacional, considerando a média de acertos em várias classes de objetos.

ODS: conjunto de metas globais definidas pela ONU para promover qualidade de vida, sustentabilidade e justiça social até 2030.

Overfitting: quando o modelo de inteligência artificial aprende em excesso os detalhes e ruídos do conjunto de treinamento, perdendo capacidade de generalizar para novos dados.

Recall (Revocação): métrica de proporção de acertos entre os casos positivos existentes.

Rede Neural: modelo de inteligência artificial inspirado no funcionamento do cérebro humano, capaz de reconhecer padrões em dados (como imagens ou séries temporais).

RMSE: métrica que calcula a dispersão dos erros, dando mais peso a erros maiores.

TABNET: sistema do DATASUS que organiza e disponibiliza dados de saúde em tabelas dinâmicas, permitindo consultas detalhadas por local, período e tipo de doença.

YOLO: algoritmo de visão computacional que detecta objetos em imagens de forma rápida e precisa, muito usado em aplicações de monitoramento.